О методах машинного обучения

Евгений Борисов

О методах машинного обучения

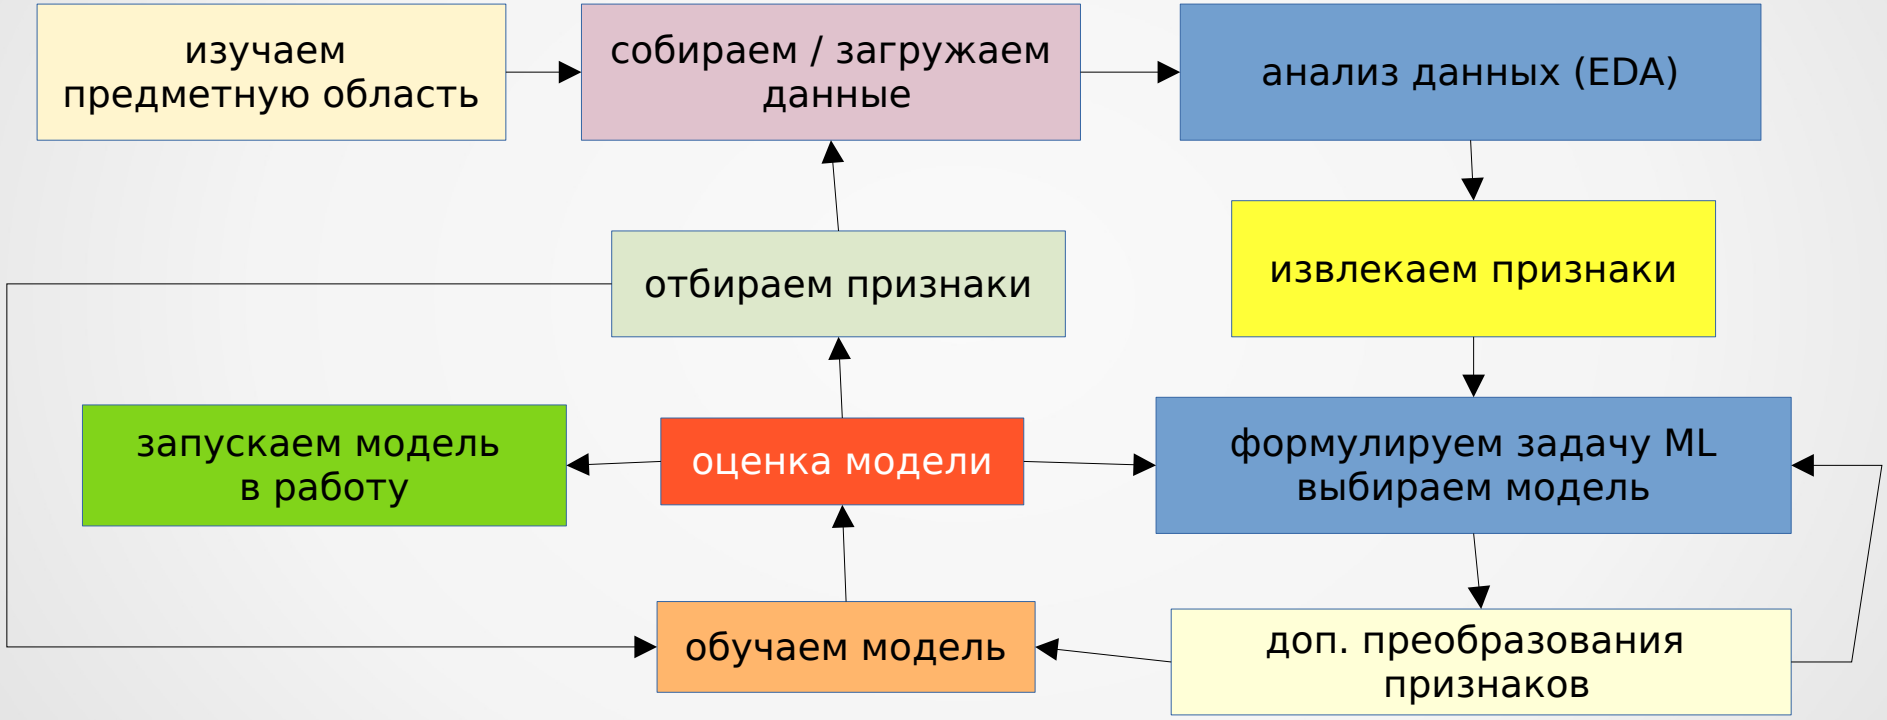

О методах машинного обучения

основные формы данных

- таблицы: CSV-файлы, Excel, БД (SQL).

- текст: сообщения, отзывы, статьи и т. д.

- временные ряды: значения, упорядоченные по времени.

- изображения: файлы JPEG, PNG и др.

- аудио: звуковые файлы, WAV, MP3.

- видео: файлы AVI, videostream

- геопространственные: координаты и др.

О методах машинного обучения

источники данных для экспериментов

- репозиторий библиотеки Scikit-Learn
- репозиторий UCI
- Kaggle
- WEB (Wikipedia)
- открытые БД в internet
- синтетические (сгенерированные) данные

О методах машинного обучения

EDA / Exploratory Data Analysis
(анализ и визуализация данных)

- понять организацию данных

- выявить пропуски и аномалии

- проверить связи между различными признаками и целевой переменной

- сформулировать и проверить гипотезы о данных,
  пример гипотезы: «клиенты-девочки тратят больше»

инструменты EDA

- визуализация данных: гистограммы, тепловые карты и т.п.

- статистический анализ: среднее, медиана, стандартное отклонение, корреляция

схема применения методов ML

признаки *(feature extraction / feature engineering)*

отображение данных, специфических для предметной области, в точки пространства признаков

Типы признаков

- количественные непрерывные ($\mathbb{R}$)
- количественные дискретные ($\mathbb{N}$)
- бинарные (да/нет)
- категориальные номинальные (цвет)
- категориальные порядковые (оценка успеваемости)
- временные отметки

собираем признаки формируем матрицу датасета

О методах машинного обучения

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

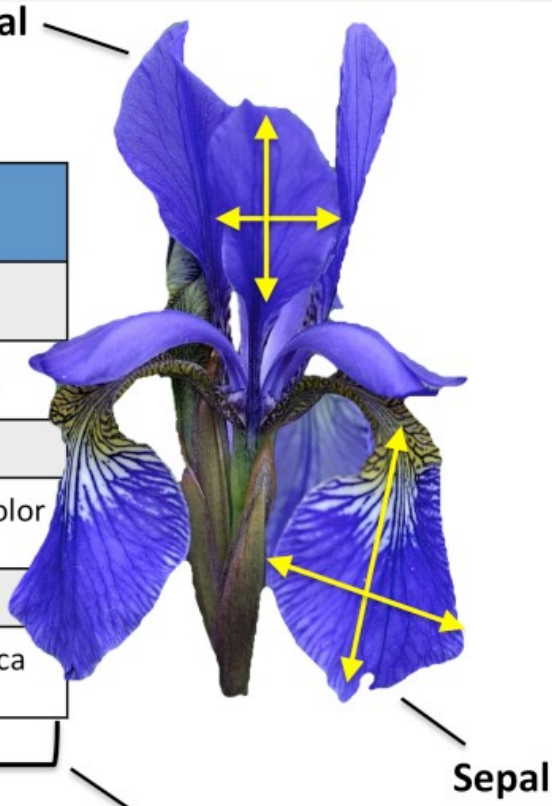

Class labels
(targets)

Features
(attributes, measurements, dimensions)

https://github.com/vishwasbasotra/Flower-Classification-WebApp

О методах машинного обучения

Основные типы задач ML

Классификация - разделение на части

Кластеризация - формирование групп

Регрессия - восстановление зависимости

О методах машинного обучения

Методы решения задач машинного обучения

способы организации данных

"с учителем" (supervised)
- размеченные данные

"без учителя" (unsupervised)
- не размеченные данные

"частичное обучение" semi-supervised
- частично размеченные данные

"с подкреплением" reinforcement
- датасет в явном виде отсутствует

О методах машинного обучения

Методы решения задач машинного обучения

способы организации данных

"с учителем" (supervised)
- размеченные данные

"без учителя" (unsupervised)
- не размеченные данные

"частичное обучение" semi-supervised
- частично размеченные данные

"с подкреплением" reinforcement
- датасет в явном виде отсутствует

модели

Метрические: k-Neighbors

Статистические: Naive Bayes

Логические: Decision Tree

Линейные: SVM, MLP

Композиции: AdaBoost

О методах машинного обучения

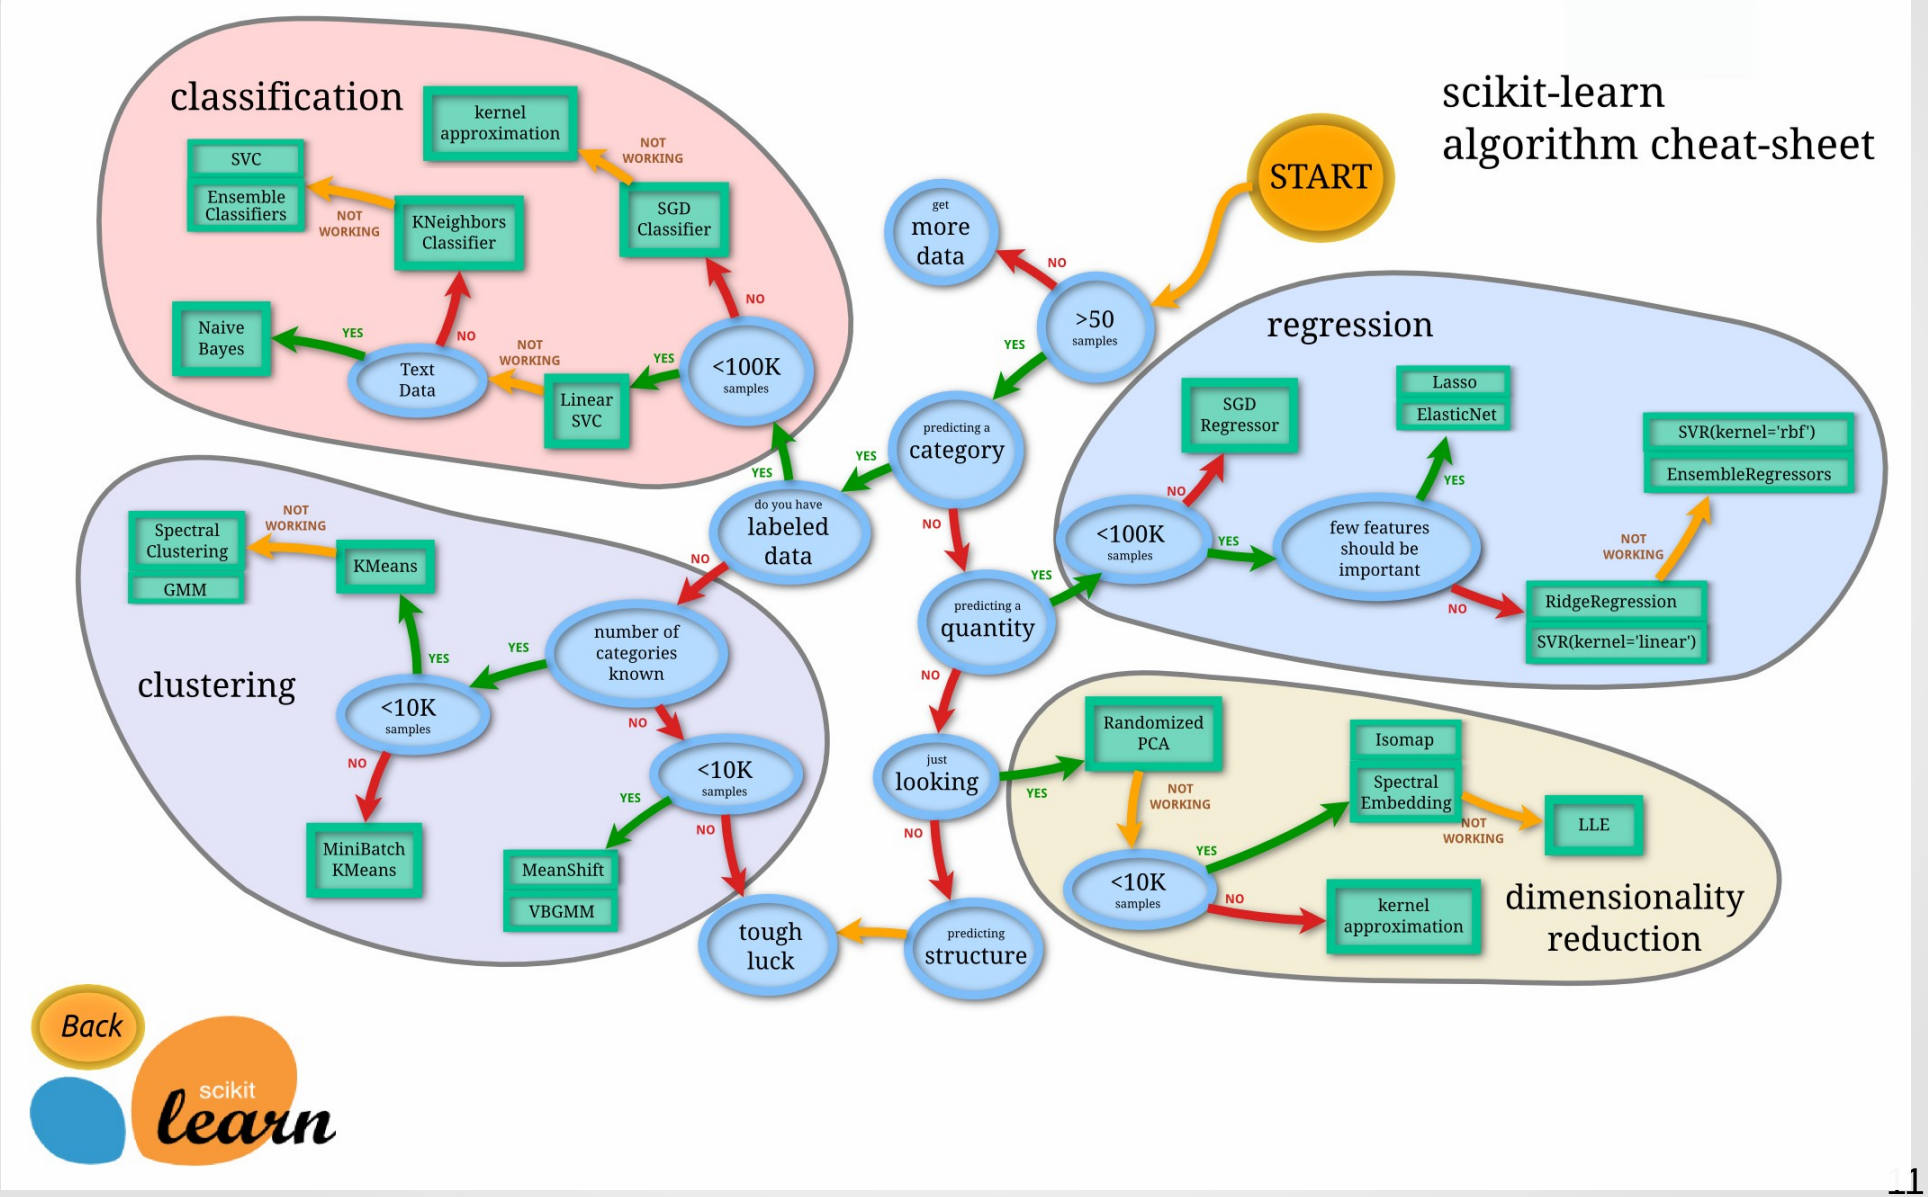

https://scikit-learn.org/stable/tutorial/machine_learning_map/

О методах машинного обучения

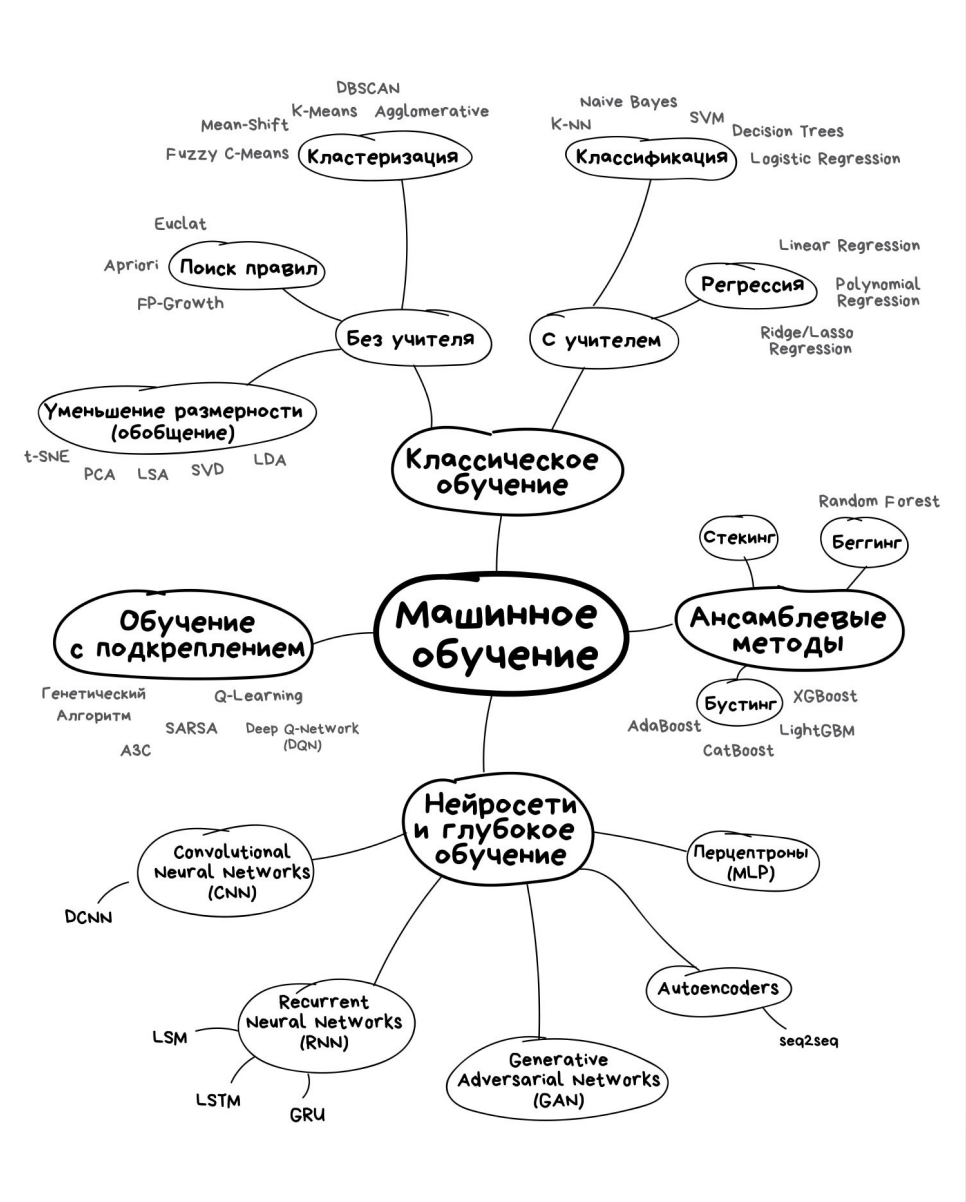

https://vas3k.blog/blog/machine_learning/

Литература

Борисов Е.С. Методы машинного обучения. 2026
https://github.com/mechanoid5/ml_lectorium_2026_I

Машинное обучение для людей
https://vas3k.ru/blog/machine_learning/

Константин Воронцов - Машинное обучение. ШАД Яндекс
https://www.youtube.com/playlist?list=PLJOzdkh8T5kp99tGTEFjH_b9zqEQiiBtC

Константин Воронцов Машинное_обучение. курс_лекций.
http://www.machinelearning.ru/wiki/index.php?title=Машинное_обучение_(курс_лекций,_К.В.Воронцов)

Радослав Нейчев - Машинное обучение, ФПМИ, 2020
https://www.youtube.com/playlist?list=PL4_hYwCyhAvZyW6qS58x4uElZgAkMVUvj

Введение в Feature Engineering для начинающих дата-сайентистов и ML-инженеров
https://habr.com/ru/companies/skillfactory/articles/842444/