EDA / Exploratory Data Analysis
анализ и визуализация данных

Евгений Борисов

Анализ и визуализация данных

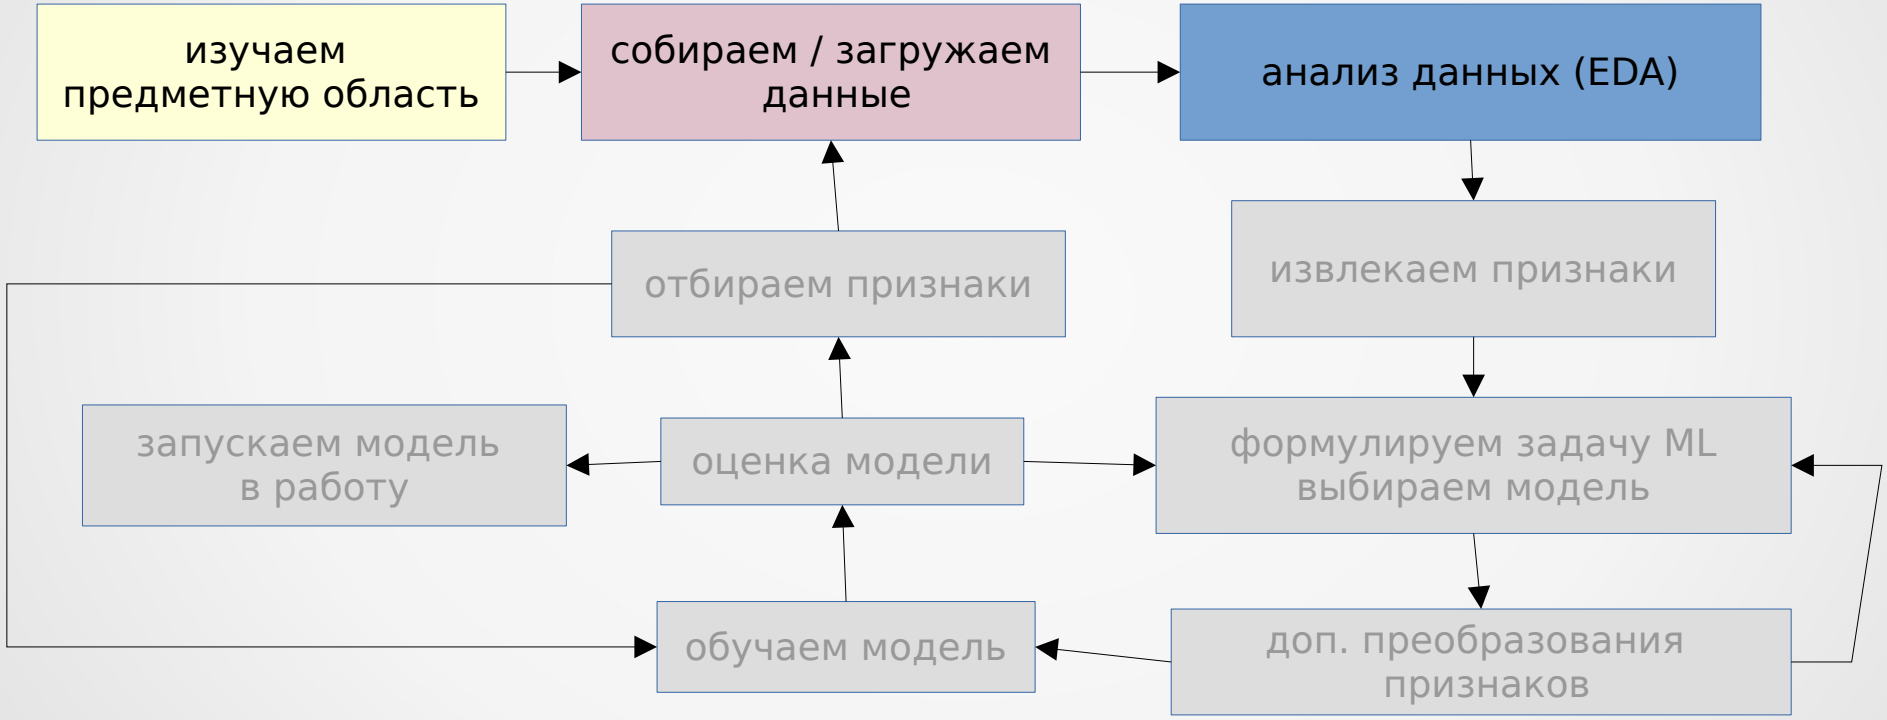

Анализ и визуализация данных

основные формы данных

- таблицы: CSV-файлы, Excel, БД (SQL).

- текст: сообщения, отзывы, статьи и т. д.

- временные ряды: значения, упорядоченные по времени.

- изображения: файлы JPEG, PNG и др.

- аудио: звуковые файлы, WAV, MP3.

- видео: файлы AVI, videostream

- геопространственные: координаты и др.

Анализ и визуализация данных

источники данных для экспериментов

- репозиторий библиотеки Scikit-Learn
- репозиторий UCI
- Kaggle
- WEB (Wikipedia)
- открытые БД в internet
- синтетические (сгенерированные) данные

Анализ и визуализация данных

Признаки (features) - отображение данных, специфических для предметной области, в точки пространства признаков

Типы признаков

- количественные непрерывные ($\mathbb{R}$)
- количественные дискретные ($\mathbb{N}$)
- бинарные (да/нет)
- категориальные номинальные (цвет)
- категориальные порядковые (оценка успеваемости)
- временные отметки

собираем признаки формируем матрицу датасета

Анализ и визуализация данных

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

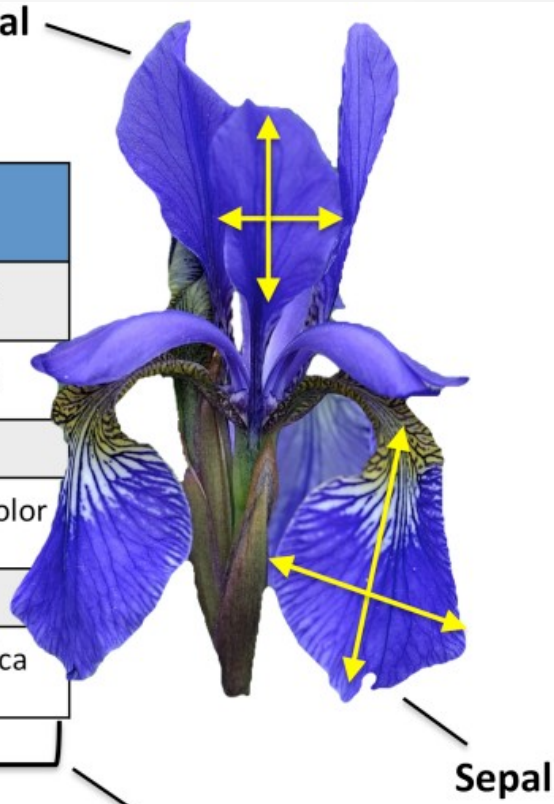

Class labels
(targets)

Features
(attributes, measurements, dimensions)

https://github.com/vishwasbasotra/Flower-Classification-WebApp

Анализ и визуализация данных

EDA / Exploratory Data Analysis
(анализ и визуализация данных)

- понять организацию данных

- выявить пропуски и аномалии

- проверить связи между различными признаками и целевой переменной

- сформулировать и проверить гипотезы о данных,
пример гипотезы: «клиенты-девочки тратят больше»

инструменты EDA

- визуализация данных: гистограммы, тепловые карты и т.п.

- статистический анализ: среднее, медиана, стандартное отклонение, корреляция

Анализ и визуализация данных

EDA / Exploratory Data Analysis

- проверка на пропуски
- проверка на дубликаты
- проверка на противоречивую разметку
- статистические характеристики: корреляции, персентили
- поиск аномалий
- визуализация: признаки попарно, PCA, статистики

Анализ и визуализация данных

обработка пропусков

- удалить объект из выборки

- заполнить средним (медианой) вещественных переменных

- заполнить наиболее частым значением для категориальных

- заменить пропуск на редкое (мало вероятное) значение

- заменить на соседнее значение для упорядоченных данных

Анализ и визуализация данных

проверка на дубликаты

- удалить дубликаты (пометить, что были дубли)

- оставить как есть (сохранить статистические характеристики)

Анализ и визуализация данных

проверка на противоречивую разметку

- переразметить и устранить конфликты

- удалить конфликтные примеры

Анализ и визуализация данных

статистические характеристики

- корреляция - зависимости признаков
- персентили - оценка значений признака
- оценка плотности распределения

$$\mathbf{r}_{XY} = \frac{\mathbf{cov}_{XY}}{\sigma_X \sigma_Y} = \frac{\sum(X-\bar{X})(Y-\bar{Y})}{\sqrt{\sum(X-\bar{X})^2 \sum(Y-\bar{Y})^2}}.$$

значения признака

	16	37	18	81	9	40	29
x	0.53	0.73	0.08	0.89	0.92	0.38	0.23

шкала персентилей

	min	10%	25%	50%	75%	95%	max
x	0.00	0.08	0.21	0.43	0.75	0.94	0.97

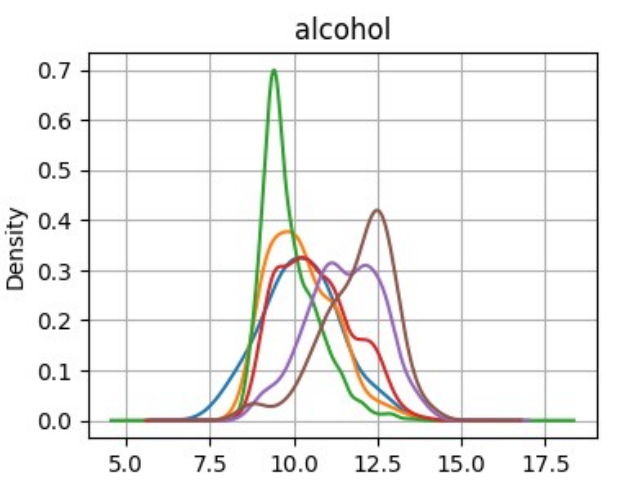

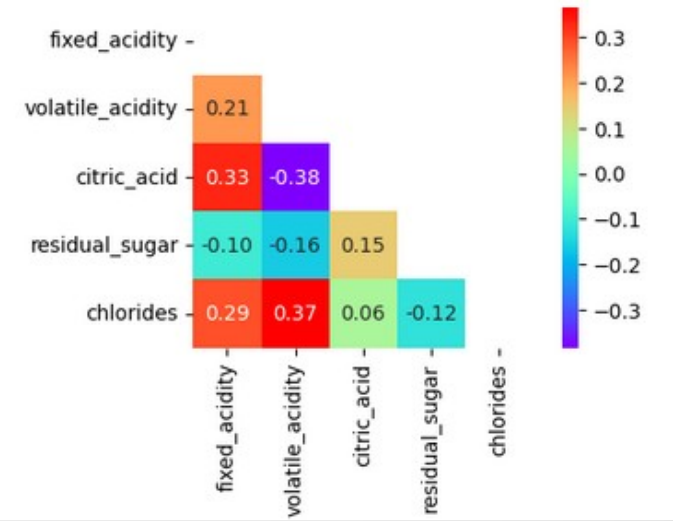

Анализ и визуализация данных

Поиск выбросов / Outlier Detection

выброс или аномалия это то, что не вписывается в общие правила

Статистические тесты - отсечение по персентелю, правило «трёх сигм»

Метрические методы - у выброса мало соседей

Итерационные методы - последовательное удаление выпуклых оболочек.

Модельные тесты - строим модель данных, точки, которые сильно отклоняются от модели - аномалии

Специальные модели ML - IsolationForest, выбросы попадают в листья на небольшой глубине дерева

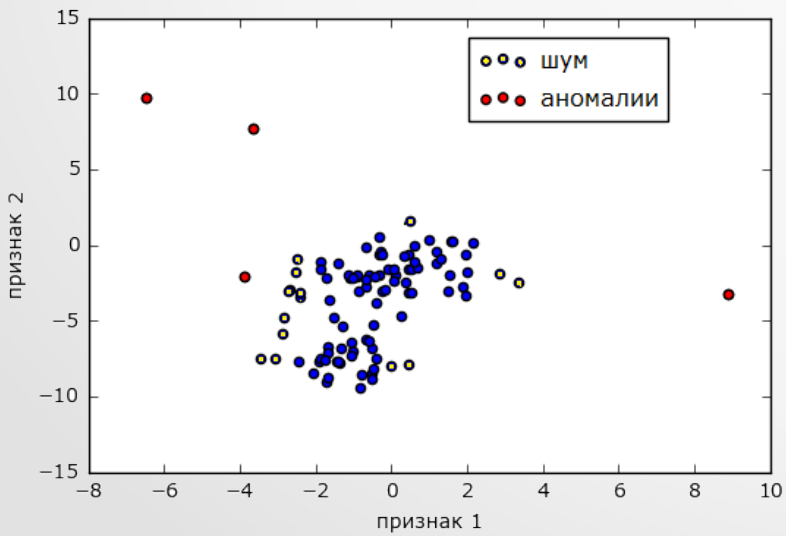

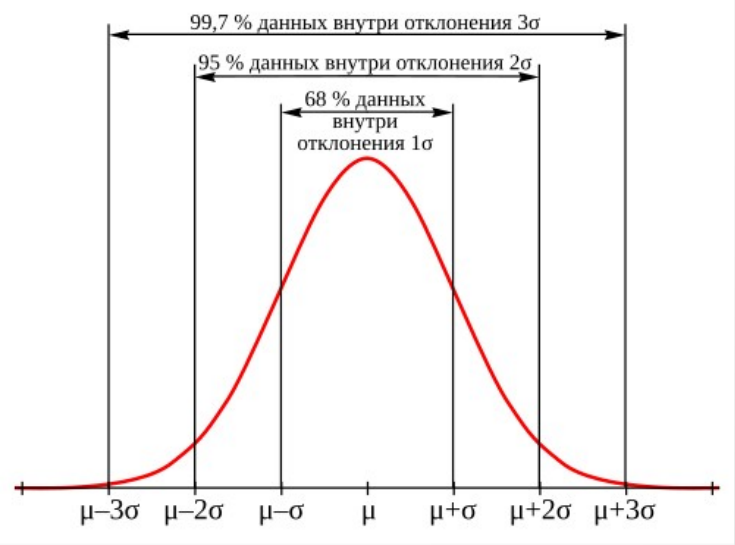

Правило 3-х сигм

с вероятностью 99.73%

$$x \in \left[\bar{x} - 3\sigma; \bar{x} + 3\sigma\right]$$

$$x \in \left[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR\right]$$

Анализ и визуализация данных

преобразования признаков

- простое масштабирование
- робастное масштабирование
- стандартизация
- log-трансформация
- преобразования категориальных признаков
- категоризация по шкале
- бинаризация

Анализ и визуализация данных

преобразования признаков (feature transformation)

- масштабирование в отрезок
  полезен для визуализации,
  легко перенести признаки на отрезок [0, 255]

$$x := \frac{x - x_{min}}{x_{max} - x_{min}}$$

- робастное масштабирование,
  медиана и межквартильный размах,
  устойчиво к выбросам

$$x := \frac{x - x_{med}}{IQR}$$

- стандартизация приведение к μ=0 и σ=1 ;
  улучшает ситуацию с выбросами;
  можно применять с метрическими методами ;

$$x := \frac{x - \mu}{\sigma}$$

- *логарифмирование*
  помогает сделать значения более равномерными

$$x := \log(x)$$

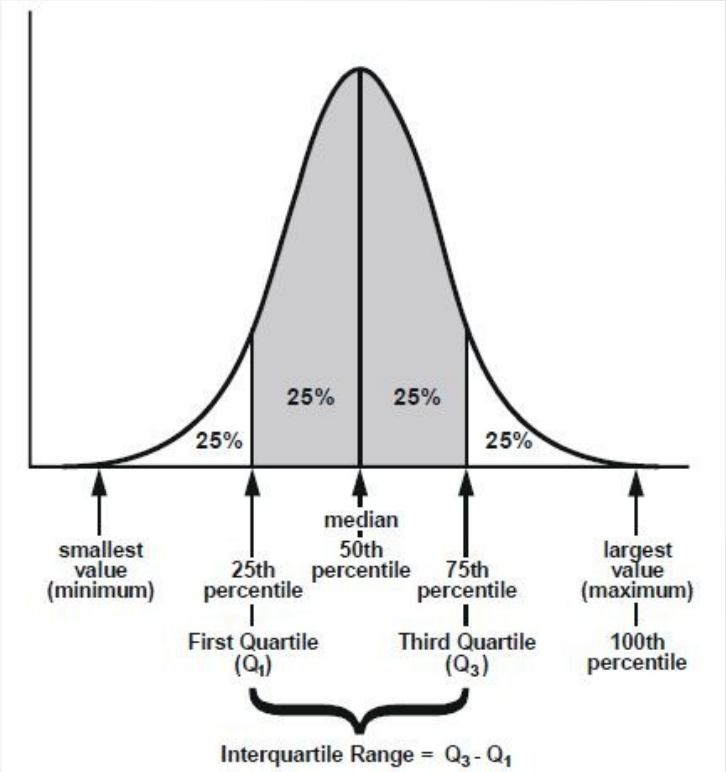

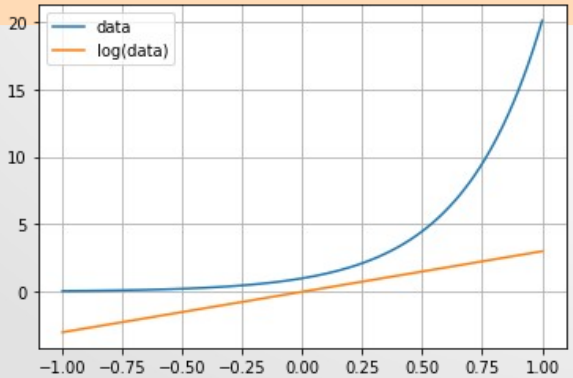

Анализ и визуализация данных

категоризация по шкале и бинаризация

уход от избыточной детализации;

помогает улучшить результаты некоторых типов моделей

значения признака

	16	37	18	81	9	40	29
x	0.53	0.73	0.08	0.89	0.92	0.38	0.23

шкала персентилей

	min	10%	25%	50%	75%	95%	max
x	0.00	0.08	0.21	0.43	0.75	0.94	0.97

категоризация по шкале

	x	cat	bin
16	0.53	3	[0, 0, 0, 1, 0, 0]
37	0.73	3	[0, 0, 0, 1, 0, 0]
18	0.08	1	[0, 1, 0, 0, 0, 0]
81	0.89	4	[0, 0, 0, 0, 1, 0]
9	0.92	4	[0, 0, 0, 0, 1, 0]
40	0.38	2	[0, 0, 1, 0, 0, 0]
29	0.23	2	[0, 0, 1, 0, 0, 0]

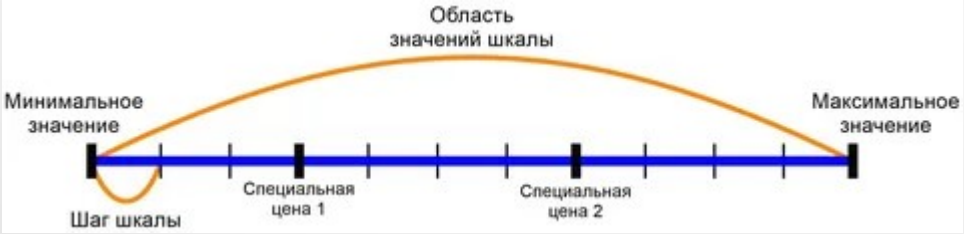

https://www.ispsystem.ru/docs/bsa/obrabotka-uslug/rabota-s-tarifami/soderyoanie-tarifnogo-plana/shkala-znachenij

Программные инструменты

Инструменты для работы с исходными данных

Pandas

GeoPandas

Scikit-Image

Librosa

NLTK

Математические методы и модели ML

Numpy

Scikit-Learn

Вспомогательные инструменты

Matplotlib

SymPy

Программные инструменты

Numerical Python https://numpy.org

Библиотека для работы с многомерными массивами

```
import numpy as np
```

```
np.array([[0,1,2],[3,4,5]],dtype=np.uint8)
```

```
array([[0, 1, 2],
       [3, 4, 5]], dtype=uint8)
```

```
np.random.rand(2,3).astype(np.float32)
```

```
array([[0.51, 0.36, 0.82],
       [0.68, 0.04, 0.89]], dtype=float32)
```

```
np.eye(i,j) # единичная матрица
```

```
array([[1., 0., 0., 0., 0.],
       [0., 1., 0., 0., 0.],
       [0., 0., 1., 0., 0.],
       [0., 0., 0., 1., 0.],
       [0., 0., 0., 0., 1.],
       [0., 0., 0., 0., 0.]])
```

циклы не используем

поэлементная обработка в цикле это медленно

векторизация вычислений

x * y - поэлементное умножение матриц

x.dot(y) - умножение матриц

np.vstack([y,x]) - объединение матриц

Программные инструменты

Библиотеки для визуализации данных 2D и 3D графикой

https://matplotlib.org https://seaborn.pydata.org

matplotlib seaborn

import matplotlib.pyplot **as** plt

import seaborn **as** sns

```
fig, ax = plt.subplots(figsize=(5,3),)
ax.plot(x, x, label='linear')  # Plot some data on the axes.
ax.plot(x, x**2, label='quadratic')  # Plot more data on the axes...
ax.plot(x, x**3, label='cubic')  # ... and some more.
ax.set_xlabel('x label')  # Add an x-label to the axes.
ax.set_ylabel('y label')  # Add a y-label to the axes.
ax.set_title("Simple Plot")  # Add a title to the axes.
ax.legend()  # Add a legend.
ax.grid()
```

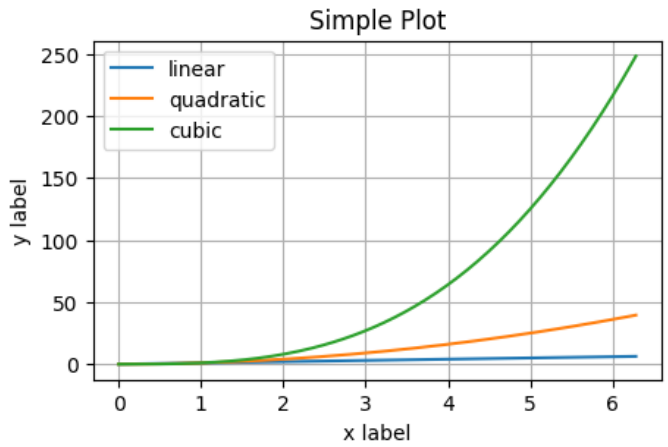

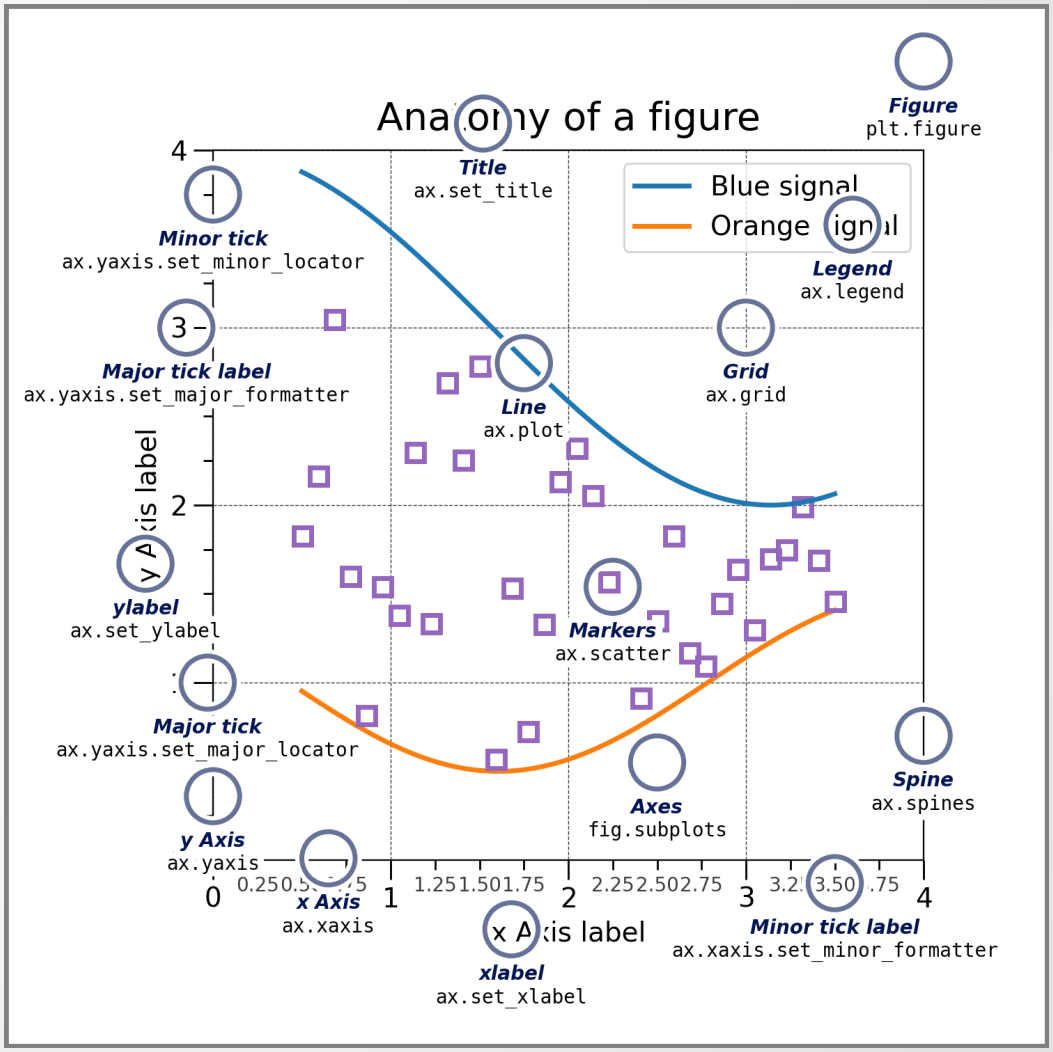

Программные инструменты

Библиотека для работы с табличными данными
https://pandas.pydata.org

import pandas **as** pd

pd.Series — столбец

pd.DataFrame — таблица

adf

x1	x2
A	1
B	2
C	3

+

bdf

x1	x3
A	T
B	F
D	T

=

x1	x2	x3
A	1	T
B	2	F
C	3	NaN

```
pd.merge(adf, bdf,
         how='left', on='x1')
```

Join matching rows from bdf to adf.

	a	b	c
1	4	7	10
2	5	8	11
3	6	9	12

```
df = pd.DataFrame(
        {"a" : [4, 5, 6],
         "b" : [7, 8, 9],
         "c" : [10, 11, 12]},
      index = [1, 2, 3])
```

```
df = pd.DataFrame(
     [[4, 7, 10],
      [5, 8, 11],
      [6, 9, 12]],
     index=[1, 2, 3],
     columns=['a', 'b', 'c'])
```

```
df[df.Length > 7]
```

Extract rows that meet logical criteria.

```
df.drop_duplicates()
```

Remove duplicate rows (only considers columns)

```
df.sample(frac=0.5)
```

Randomly select fraction of rows.

```
df.sample(n=10)
```

Randomly select n rows.

```
df.nlargest(n, 'value')
```

Select and order top n entries.

```
df.nsmallest(n, 'value')
```

Select and order bottom n entries.

```
df.head(n)
```

Select first n rows.

```
df.tail(n)
```

Select last n rows.

```
df.query('Length > 7')
df.query('Length > 7 and Width < 8')
```

```
df.plot.hist()
```

Histogram for each column

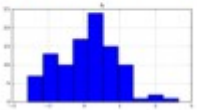

https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf

Программные инструменты

GeoPandas

Библиотека для работы с табличными геоданными

https://geopandas.org

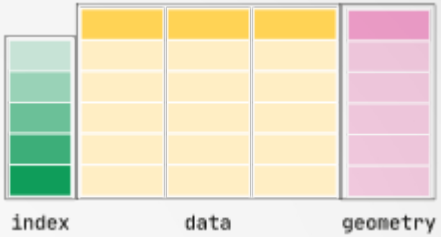

import geopandas **as** gpd

```
grid.merge(grid_values,on='hex_id').explore('priceM',cmap='rainbow') #'area_name', legend=True)
```

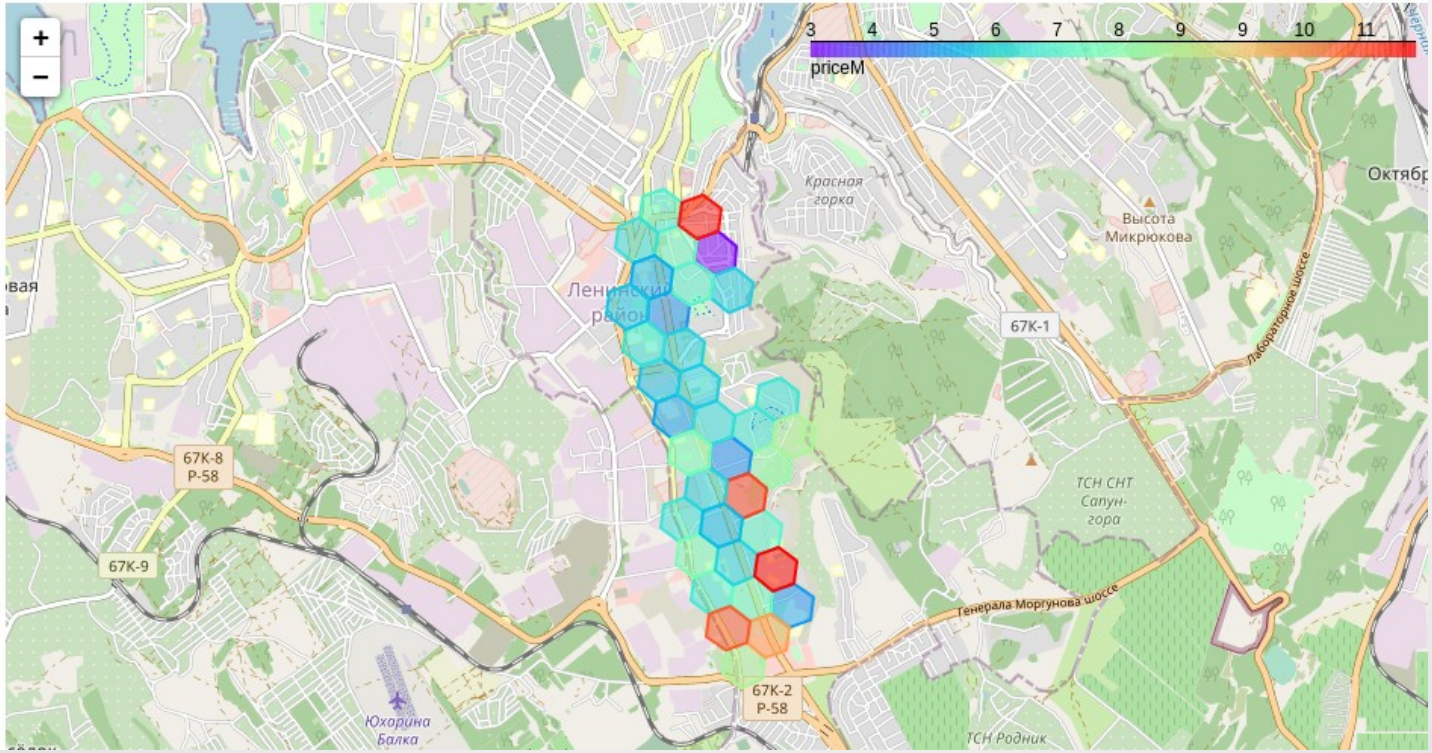

Программные инструменты

scikit-image
image processing in python

Библиотека для работы с картинками

https://scikit-image.org

from skimage **import** data, io, filters

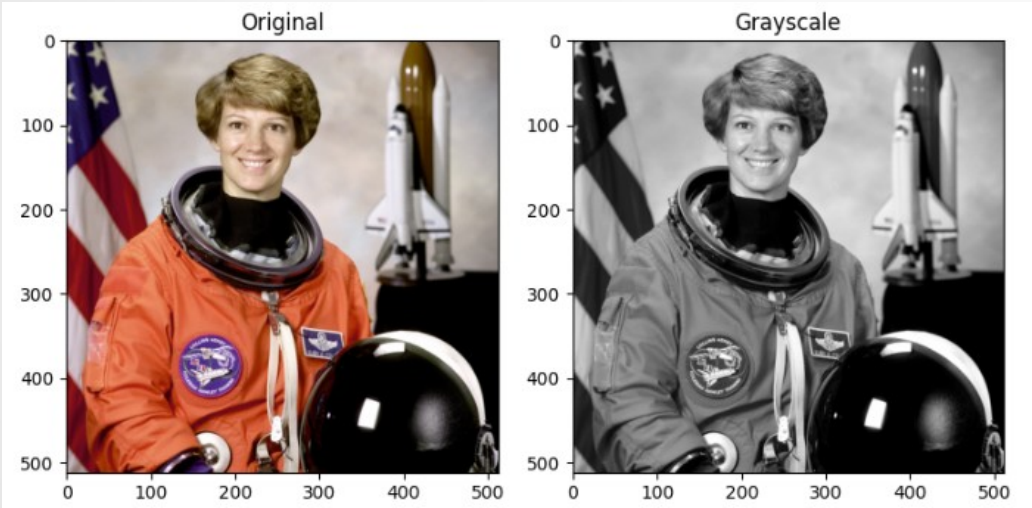

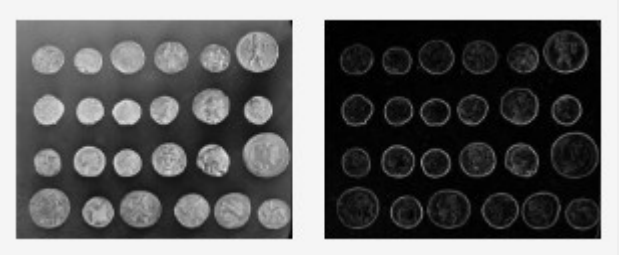

```
from skimage import data, io, filters

image = data.coins()
# ... or any other NumPy array!
edges = filters.sobel(image)
io.imshow(edges)
io.show()
```

Программные инструменты

librosa

Библиотека для работы со звуком

https://librosa.org

```
from IPython.display import  Audio

filename = librosa.example('nutcracker')

Audio(filename=filename,autoplay=True)
```

```
Downloading file 'Kevin_MacLeod_-_P_I_Tcha
a/audio/Kevin_MacLeod_-_P_I_Tchaikovsky_Da
```

0:19 / 1:59

```
# librosa.display.waveshow(y)
plt.figure(figsize=(11, 5))
librosa.display.waveshow(y=y, sr=sr, alpha=.7)
```

```
<librosa.display.AdaptiveWaveplot at 0x7f854028b190>
```

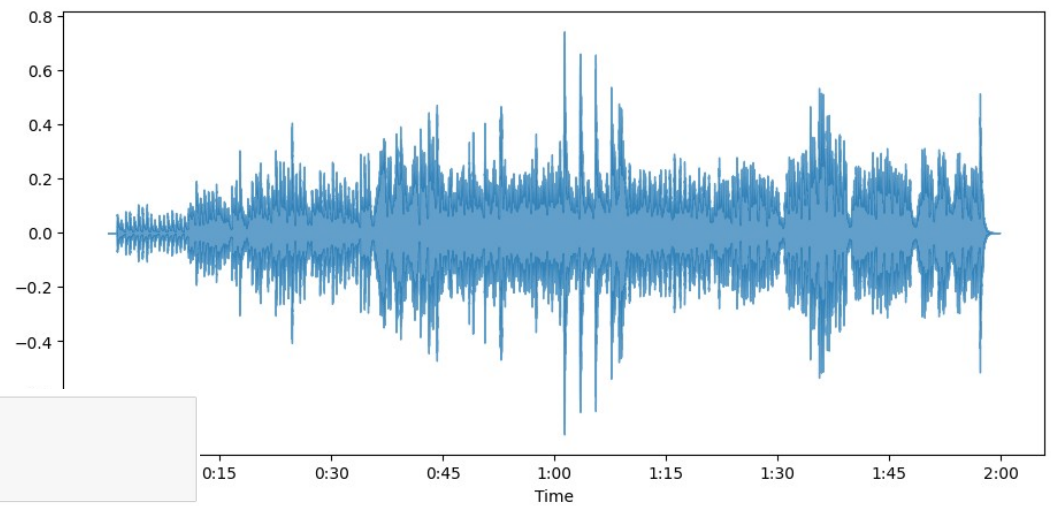


```
# compute the spectrogram
X = librosa.stft(y)
Xdb = librosa.amplitude_to_db(abs(X))
plt.figure(figsize=(14, 5))
librosa.display.specshow(Xdb, sr=sr, x_axis='time', y_axis='hz')
```

```
<matplotlib.collections.QuadMesh at 0x7f85401f93f0>
```

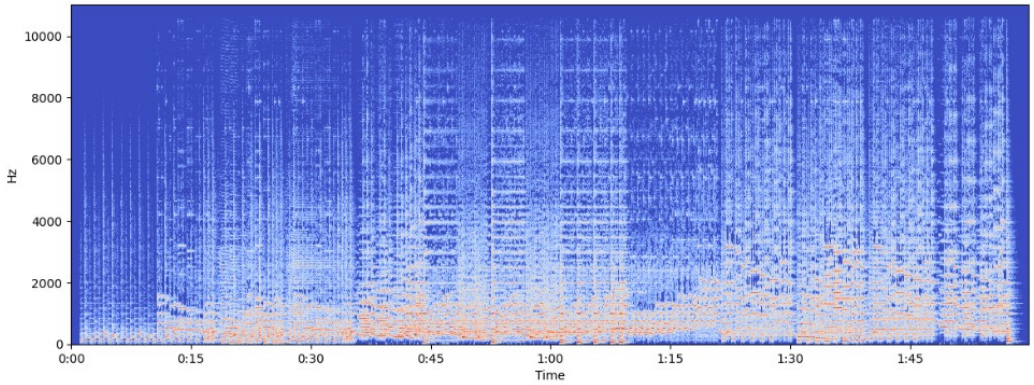

Программные инструменты

Библиотека для работы с текстами

https://www.nltk.org

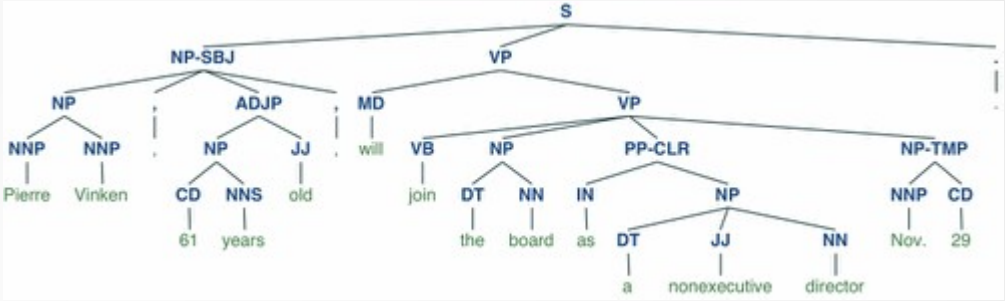


```
>>> import nltk
>>> sentence = """At eight o'clock on Thursday morning
... Arthur didn't feel very good."""
>>> tokens = nltk.word_tokenize(sentence)
>>> tokens
['At', 'eight', "o'clock", 'on', 'Thursday', 'morning',
'Arthur', 'did', "n't", 'feel', 'very', 'good', '.']
>>> tagged = nltk.pos_tag(tokens)
>>> tagged[0:6]
[('At', 'IN'), ('eight', 'CD'), ("o'clock", 'JJ'), ('on', 'IN'),
('Thursday', 'NNP'), ('morning', 'NN')]
```

Программные инструменты

Библиотека методов ML

https://scikit-learn.org

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.
Algorithms: SVM, nearest neighbors, random forest, and more...

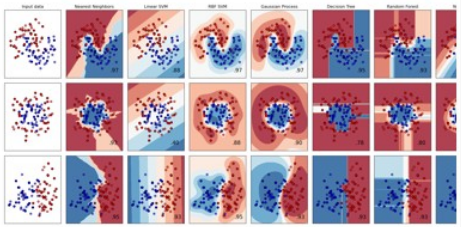

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.
Algorithms: SVR, nearest neighbors, random forest, and more...

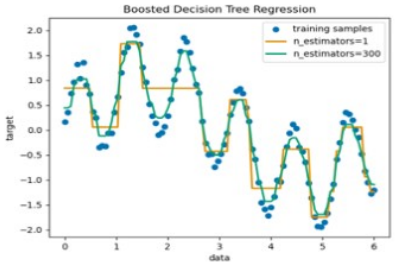

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes
Algorithms: k-Means, spectral clustering, mean-shift, and more...

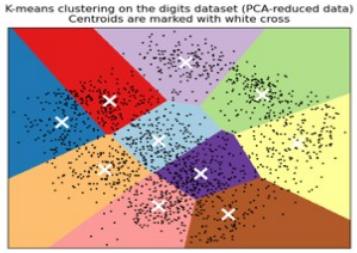

Preprocessing

Feature extraction and normalization.

Applications: Transforming input data such as text for use with machine learning algorithms.
Algorithms: preprocessing, feature extraction, and more...

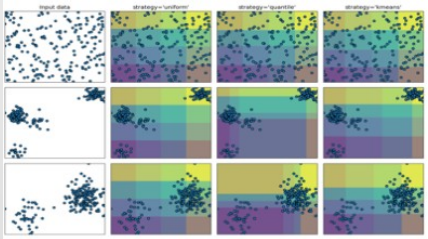

Model selection

Comparing, validating and choosing parameters and models.

Applications: Improved accuracy via parameter tuning
Algorithms: grid search, cross validation, metrics, and more...

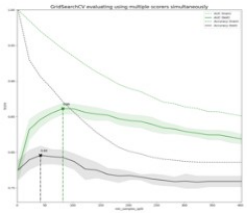

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency
Algorithms: PCA, feature selection, non-negative matrix factorization, and more...

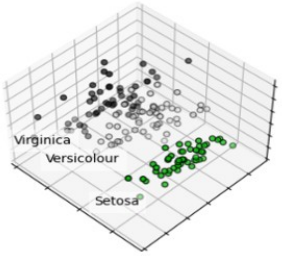

Программные инструменты

SymPy - Библиотека символьных вычислений

https://www.sympy.org

```
from sympy.abc import x,y,w,o,u
from sympy import *
```

```
# определим выражение
expr = log(1+exp(-x))
display( expr )
```

$$\log\left(1+e^{-x}\right)$$

```
# возьмём производную и упростим результат
expr.diff(x).simplify()
```

$$-\frac{1}{e^{x}+1}$$

Литература

Борисов Е.С. Методы машинного обучения. 2026
https://github.com/mechanoid5/ml_lectorium_2026_I

Криволапов С.Я., Хрипунова М.Б. Математика на Python : учебник — Москва: КНОРУС, 2022

Дейтел П., Дейтел Х. Python: Искусственный интеллект, большие данные и облачные вычисления. — СПб.: Питер, 2020.

Александр Дьяконов Поиск аномалий
https://dyakonov.org

Александр Куменко Как я победил в конкурсе BigData от Beeline.
https://habr.com/post/270367/

Введение в Feature Engineering для начинающих дата-сайентистов и ML-инженеров
https://habr.com/ru/companies/skillfactory/articles/842444/

Умная нормализация данных
https://habr.com/ru/articles/527334/

100 numpy exercises https://github.com/rougier/numpy-100

100 pandas puzzles https://github.com/ajcr/100-pandas-puzzles/