

Автоматическая обработка звуковых образов.

Евгений Борисов

Обработка звуковых образов

Задачи



- Audio classification
- Speech recognition / speaker verification / speaker diarization
- Audio denoising / audio upsampling
- Music Information Retrieval (Mood Classification)
- Audio styling
- Audio synthesis

Обработка звуковых образов

звуковые волны


регулярные изменения давления воздуха

порождаются механической вибрацией объектов




Обработка звуковых образов

частота



амплитуда



$$y(t) = A \cdot \sin(2\pi f t + \phi)$$

ϕ – амплитуда ;

f – частота ;


t – время ;

ϕ – фаза ;

Частота определяет высоту звука,



Амплитуда - громкость

фаза



Обработка звуковых образов

ВЫСОКИЕ И НИЗКИЕ ЗВУКИ



Обработка звуковых образов


ТОН И ЧАСТОТА

Тон - восприятие частоты человеком

логарифмическое восприятие,
человек различает низкие звуки лучше чем высокие

$$F(p) = 440 \cdot 2^{\frac{p-69}{12}}$$

Тембр — многомерная характеристика
составляющих звука



Note name	A7#	106	107	B7	A7#	105	106	B7	A7#	103	104	B7	A7#	101	102	B7	A7#	99	100	B7	A7#	97	98	B7	A7#	95	96	B7	A7#	93	94	B7	A7#	91	92	B7	A7#	89	90	B7	A7#	87	88	B7	A7#	85	86	B7	A7#	83	84	B7	A7#	81	82	B7	A7#	79	80	B7	A7#	77	78	B7	A7#	75	76	B7	A7#	73	74	B7	A7#	71	72	B7	A7#	69	70	B7	A7#	67	68	B7	A7#	65	66	B7	A7#	63	64	B7	A7#	61	62	B7	A7#	59	60	B7	A7#	57	58	B7	A7#	55	56	B7	A7#	53	54	B7	A7#	51	52	B7	A7#	49	50	B7	A7#	47	48	B7	A7#	45	46	B7	A7#	43	44	B7	A7#	41	42	B7	A7#	39	40	B7	A7#	37	38	B7	A7#	35	36	B7	A7#	33	34	B7	A7#	31	32	B7	A7#	29	30	B7	A7#	27	28	B7	A7#	25	26	B7	A7#	23	24	B7	A7#	21	22	B7	A7#	19	20	B7	A7#	17	18	B7	A7#	15	16	B7	A7#	13	14	B7	A7#	11	12	B7	A7#	9	10	B7	A7#	7	8	B7	A7#	5	6	B7	A7#	3	4	B7	A7#	1	2	B7	A7#	A0#																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																				
-----------	-----	-----	-----	----	-----	-----	-----	----	-----	-----	-----	----	-----	-----	-----	----	-----	----	-----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	----	----	----	-----	---	----	----	-----	---	---	----	-----	---	---	----	-----	---	---	----	-----	---	---	----	-----	-----	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--

440 Hz 880 Hz

Обработка звуковых образов

Громкость — субъективное восприятие человеком, зависит от возраста, частоты и др.

мощность звука - энергия передаваемая от источника в единицу времени (Вт, W)

интенсивность звука - мощность переданная на единицу площади (Вт/м², W/m²)

уровень интенсивности — логарифмическое восприятие интенсивности человеком (dB)


порог слышимости, threshold of hearing (TOH)
 $TOH = 10^{-12} \text{ W/m}^2$

болевой порог громкости, threshold of pain (TOP)
 $TOP = 10 \text{ W/m}^2$



$$dB(I) = 10 \cdot \log_{10} \frac{I}{TOH}$$

$$dB(TOH) = 10 \cdot \log_{10} \frac{TOH}{TOH} = 10 \cdot \log_{10} 1 = 0$$





Обработка звуковых образов

представление звукового сигнала



Обработка звуковых образов

представление звукового сигнала — частота дискретизации



Sampling rate

$$Sr = \frac{1}{T}$$

Теорема Найквиста – Шенона – Котельникова

$$f_N = \frac{Sr}{2}$$




Если максимальная частота воспринимаемая человеком 22050Гц,

То для воспроизведения без (существенных) потерь минимальная частота дискретизации звукового сигнала (sample rate) должна быть 44100Гц (CD качество музыки)

Обработка звуковых образов

представление звукового сигнала - quantization, bit depth



bit depth - насколько точно будем кодировать уровень сигнала

CD качество

Sample rate = 44100 Hz

bit depth = 16 bits


$$2^{16} = 65536$$



Обработка звуковых образов

извлечение признаков из звуковых сигналов



- моментальная характеристика (точечная)
- характеристика сегмента (на отрезке)
- общая характеристика (всё целиком)



различные типы звуковых сигналов - разные наборы признаков

- Обработка музыкальных образов (Music Information Retrieval, MIR)
- Задача распознавания речи
- Прочее

- Amplitude envelope
- Root-mean square energy
- Zero crossing rate
- Spectrogram
- Spectral centroid
- Mel-spectrogram



Обработка звуковых образов

Типы аудиопризнаков:


Временные характеристики (Time-domain features)

Частотные характеристики (frequency domain features)

Обработка звуковых образов

Временные характеристики (Time-domain features)

считаем характеристику для каждого фрейма и агрегируем результаты




Обработка звуковых образов

Временные характеристики (Time-domain features)

считаем характеристику для каждого фрейма и агрегируем результаты

Amplitude envelope (AE)

$$AE(t) = \max_{k=t \cdot K}^{(t+1) \cdot K - 1} s(k)$$




характеристика чувствительна к выбросам

можно использовать для определения жанра музыки

Root-mean-square energy (RMS)

$$RMS(t) = \sqrt{\frac{1}{K} \sum_{k=t \cdot K}^{(t+1) \cdot K - 1} s^2(k)}$$




определяет уровень громкости

менее чувствительна к выбросам чем AE

можно использовать для сегментации аудио

Zero-crossing rate (ZCR)

$$ZCR(t) = \frac{1}{2} \sum_{k=t \cdot K}^{(t+1) \cdot K - 1} |\text{sign}(s(k)) - \text{sign}(s(k+1))|$$



детектор ритмичной музыки

детектор голоса


Обработка звуковых образов



Частотные характеристики (frequency domain features)

преобразование Фурье - разбираем сигнал на частотные составляющие



$$G(f) = \int_{-\infty}^{\infty} g(t) e^{-2\pi i f t} dt.$$



Обработка звуковых образов

Частотные характеристики (frequency domain features)




разбираем сигнал на частотные составляющие, считаем характеристику и агрегируем результаты



Обработка звуковых образов

Частотные характеристики (frequency domain features)


преобразование Фурье - разбираем сигнал на частотные составляющие



Обработка звуковых образов


Частотные характеристики (frequency domain features)

Прямое и обратное преобразование Фурье



$$\hat{g}(f) = \int g(t) \cdot e^{-i2\pi ft} dt$$



$$g(t) = \int c_f \cdot e^{i2\pi ft} df$$



Обработка звуковых образов

Частотные характеристики (frequency domain features)

дискретное преобразование Фурье DFT



$$\hat{g}(f) = \int g(t) \cdot e^{-i2\pi ft} dt$$

$$\hat{x}(f) = \sum_n x(n) \cdot e^{-i2\pi fn}$$



Обработка звуковых образов



Частотные характеристики (frequency domain features)

разбираем сигнал на частотные составляющие, считаем характеристику и агрегируем результаты

Спектрограммы — разбиваем образ на несколько перекрывающихся окон, в каждом применяем FT




Обработка звуковых образов

Частотные характеристики (frequency domain features)

Мэл-спектрограммы


логарифмическое восприятие,
человек различает низкие частоты лучше чем высокие

выполняем логарифмическое преобразование Hz $\rightarrow$ Mel



$$m = 2595 \cdot \log\left(1 + \frac{f}{500}\right)$$

$$f = 700(10^{m/2595} - 1)$$




Обработка звуковых образов

Частотные характеристики (frequency domain features)


Мэл-кепстральные коофициенты (Mel-Frequency Cepstral Coefficients, MFCC)

Spectrum - Cepstrum



$$C(x(t)) = F^{-1} \left[\log \left(F \left[x(t) \right] \right) \right]$$

Time-domain signal $x(t)$ is transformed into the Spectrum $F[x(t)]$, then the Log spectrum $\log(F[x(t)])$ is calculated, and finally the Cepstrum $C(x(t))$ is obtained via the inverse Fourier transform F^{-1} .



Mel-Frequency Cepstral Coefficients Explained Easily
https://www.youtube.com/watch?v=4_SH2nfbQZ8

Обработка звуковых образов

Обработка музыкальных образов (Music Information Retrieval, MIR)

задачи

- разделение звучания музыкальных инструментов
- классификация музыкальных образов
- оценка настроения музыкального образа

характеристики

- ритм
- тон
- тембр
- гармоничность

Обработка звуковых образов

Литература

git clone https://github.com/mechanoid5/ml_lectorium

Дауни Аллен Цифровая обработка сигналов на языке Python. 2017

Allen B.Downey Think DSP. Digital Signal Processing in Python. 2014

Meinard Müller, Brian McFee Instructional material for the Music Information Retrieval Workshop at CCRMA, Stanford University, 2014-18.

<https://github.com/bmcfee/stanford-mir>

Valerio Velardo The Sound of AI : Audio Signal Processing for Machine Learning

<https://www.youtube.com/playlist?list=PL-wATfeyAMNqIee7cH3q1bh4QJFAaeNv0>

<https://github.com/musikalkemist/AudioSignalProcessingForML>